

DOCUMENTO DE ANÁLISIS Y RESULTADOS TÉCNICOS

Programa: Análisis y Desarrollo de Software (ADSO) | **Módulo:** Ciencia de Datos con Python - Sesión 5
Cliente: DataAnalytics Colombia S.A.S. | **Modalidad:** Trabajo Colaborativo

1. RESUMEN EJECUTIVO Y OBJETIVOS

El presente informe documenta la ejecución del proceso de **Data Wrangling** realizado sobre la base de datos de clientes de **DataAnalytics Colombia S.A.S.**. La base original presentaba severos problemas de calidad de datos, incluyendo valores nulos, registros duplicados, inconsistencias ortográficas en nombres de ciudades, categorías y estados, así como valores fuera de rango en edades e importes de compra negativos. El proyecto aplicó la librería Pandas en Python para realizar un diagnóstico exhaustivo, saneamiento de inconsistencias y segmentación comercial estratificada.

2. MATRIZ COMPARATIVA: ANTES Y DESPUÉS DEL WRANGLING

Métrica de Calidad	Dataset Original	Dataset Limpio	Estado / Impacto
Total de Registros	123	115	-8 duplicados eliminados
Valores Nulos Totales	32	0	100% Imputados / Corregidos
Registros Duplicados	8	0	Deduplicación completa (drop_duplicates)
Variaciones de Ciudad	25 variantes inconsistentes	6 ciudades estándar	Normalizado con acentos y mayúsculas
Rango de Edades Válidas	0.0 a 150.0 años	18 a 74 años	Filtro/Imputación mediana (18-100)
Mínimo Valor de Compra	\$-3,200,000	\$50,000	Saneamiento de valores negativos (abs)

3. JUSTIFICACIÓN TÉCNICA DE LAS ESTRATEGIAS DE WRANGLING

- Tratamiento de Nulos:** Los campos cuantitativos (*Edad*, *Compras*, *ValorCompra*) fueron imputados con la mediana estadística de la distribución limpia para evitar la distorsión producida por la media en presencia de sesgos. Los campos categóricos (*Ciudad*, *Genero*, *Categoria*, *Estado*) se imputaron mediante la moda categórica.
- Normalización Textual:** Se aplicó `str.strip()` para eliminar espacios invisibles y diccionarios de reemplazo mapeados a expresiones regulares para estandarizar formas disímiles (ej: *medellin*, *Medelin*, *MEDELLIN* → **Medellín**).
- Corrección de Anomalías Numéricas:** Se convirtieron los valores de compra negativos mediante su valor absoluto `abs()`, interpretando errores de tipeo o signo en los sistemas de captura originales.

4. RESULTADOS DE LA SEGMENTACIÓN COMERCIAL Y MÉTRICAS CLAVE

Segmento Comercial	Cant. Clientes	Prom. Edad	Prom. Valor Compra	Venta Total (\$)
Datos Limpios (Total)	115	45.1 yrs	\$4,520,870	\$519,900,000
Segmento A: Premium (>5M)	43	42.9 yrs	\$8,874,419	\$381,600,000

Segmento B: Jóvenes (18-25)	11	21.2 yrs	\$4,918,182	\$54,100,000
Segmento C: Ciudades Principales	72	46.5 yrs	\$5,019,444	\$361,400,000
Segmento D: Clientes Activos	60	46.7 yrs	\$4,872,500	\$292,350,000
Segmento E: Alto Potencial	18	39.9 yrs	\$5,861,111	\$105,500,000

5. CONCLUSIONES Y ENTREGABLES GENERADOS

- 1. **Higiene de Datos Garantizada:** El archivo clientes_limpios.csv constituye una fuente única de la verdad completamente limpia y estructurada sin duplicados ni nulos.
- 2. **Reporte Multicapa en Excel:** Se generó el archivo reporte_segmentacion.xlsx con 7 hojas interactivas que permiten a los equipos de Marketing y Ventas consultar segmentos específicos de forma inmediata.
- 3. **Segmento de Mayor Impacto:** El *Segmento E (Alto Potencial)* representa a 16 clientes activos de 25-50 años con compras frecuentes (>5) y alto gasto, ideales para campañas prioritarias de fidelización.